Lab09

AUTHOR
Heloisa Franco Gomes - 187932

Configuração

```
import numpy as np
import pandas as pd
from plotnine import *
from plotnine.data import diamonds
```

Questão 1

```
print(diamonds.shape)
diamonds.head()
```

```
(53940, 10)
```

	carat	cut	color	clarity	depth	table	price	x	y	z
0	0.23	Ideal	E	SI2	61.5	55.0	326	3.95	3.98	2.43
1	0.21	Premium	E	SI1	59.8	61.0	326	3.89	3.84	2.31
2	0.23	Good	E	VS1	56.9	65.0	327	4.05	4.07	2.31
3	0.29	Premium	I	VS2	62.4	58.0	334	4.20	4.23	2.63
4	0.31	Good	J	SI2	63.3	58.0	335	4.34	4.35	2.75

```
diamonds.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 53940 entries, 0 to 53939
Data columns (total 10 columns):
 #   Column   Non-Null Count  Dtype   
---  ------   --------------  -----   
 0   carat    53940 non-null  float64 
 1   cut      53940 non-null  category
 2   color    53940 non-null  category
 3   clarity  53940 non-null  category
 4   depth    53940 non-null  float64 
 5   table    53940 non-null  float64 
 6   price    53940 non-null  int64   
 7   x        53940 non-null  float64 
 8   y        53940 non-null  float64 
 9   z        53940 non-null  float64 
dtypes: category(3), float64(6), int64(1)
memory usage: 3.0 MB
```

```
diamonds["cut"] = pd.Categorical(diamonds["cut"],
    categories=["Fair","Good","Very Good","Premium","Ideal"], ordered=True)
diamonds["color"] = pd.Categorical(diamonds["color"],
    categories=["D","E","F","G","H","I","J"], ordered=True)
diamonds["clarity"] = pd.Categorical(diamonds["clarity"],
    categories=["I1","SI2","SI1","VS2","VS1","VVS2","VVS1","IF"], ordered=True)
```

Exploração com SQL via DuckDB

```
import duckdb
con = duckdb.connect()
con.register("diamonds", diamonds)
con.execute("""
    SELECT cut,
           COUNT(*)             AS n,
           ROUND(AVG(price), 0) AS preco_medio,
           ROUND(AVG(carat), 2) AS carat_medio
    FROM diamonds
    GROUP BY cut
    ORDER BY preco_medio DESC
""").df()
```

	cut	n	preco_medio	carat_medio
0	Premium	13791	4584.0	0.89
1	Fair	1610	4359.0	1.05
2	Very Good	12082	3982.0	0.81
3	Good	4906	3929.0	0.85
4	Ideal	21551	3458.0	0.70

Questão 2

Primeiro, um gráfico simples:

```
p_base = ggplot(diamonds, aes("carat", "price")) + geom_point()
p_base
```

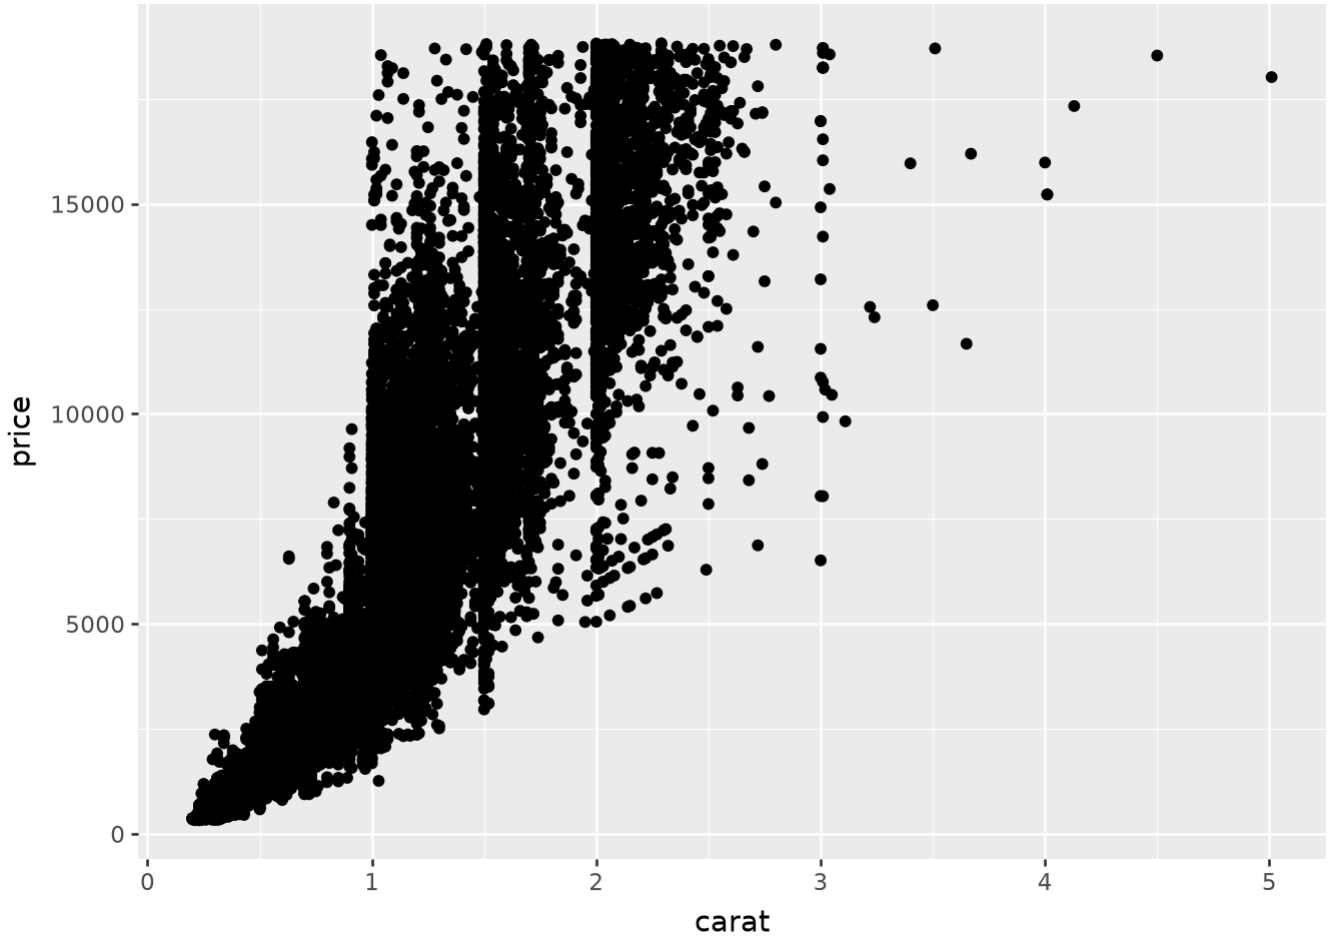
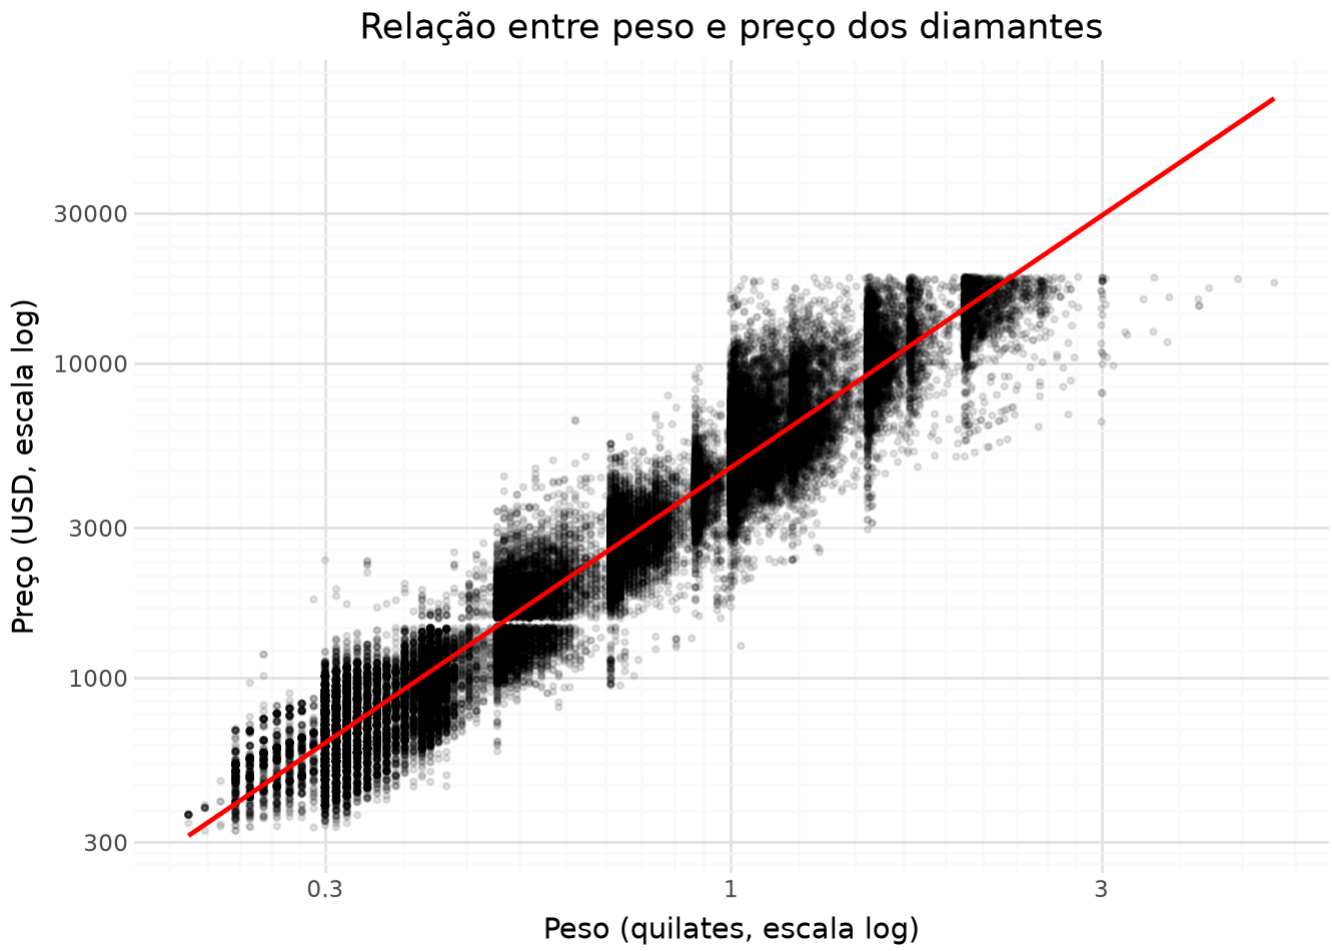


Gráfico melhorado:

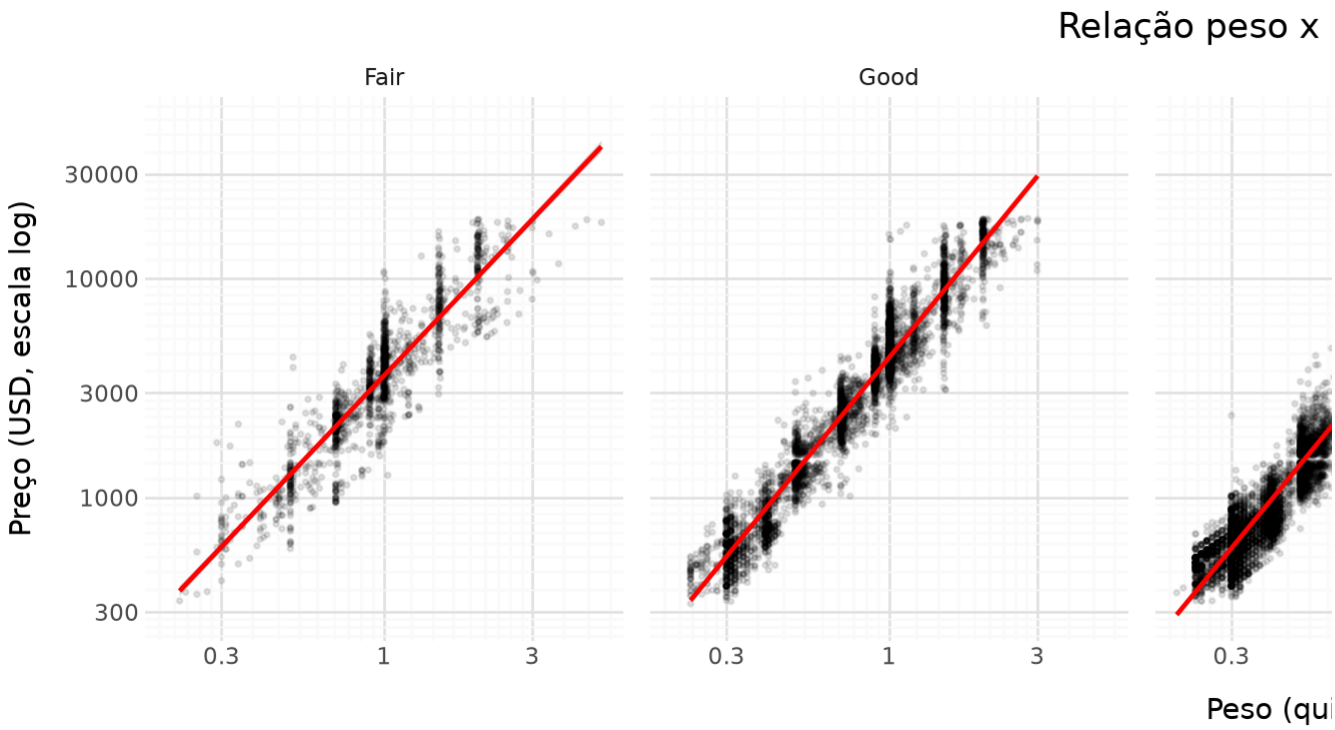
```
p2 = (
    ggplot(diamonds, aes("carat", "price"))
    + geom_point(alpha=0.1, size=0.8)
    + geom_smooth(method="lm", color="red")
    + scale_x_log10()
    + scale_y_log10()
    + labs(title="Relação entre peso e preço dos diamantes",
           x="Peso (quilates, escala log)",
           y="Preço (USD, escala log)")
    + theme_minimal()
)
p2
```



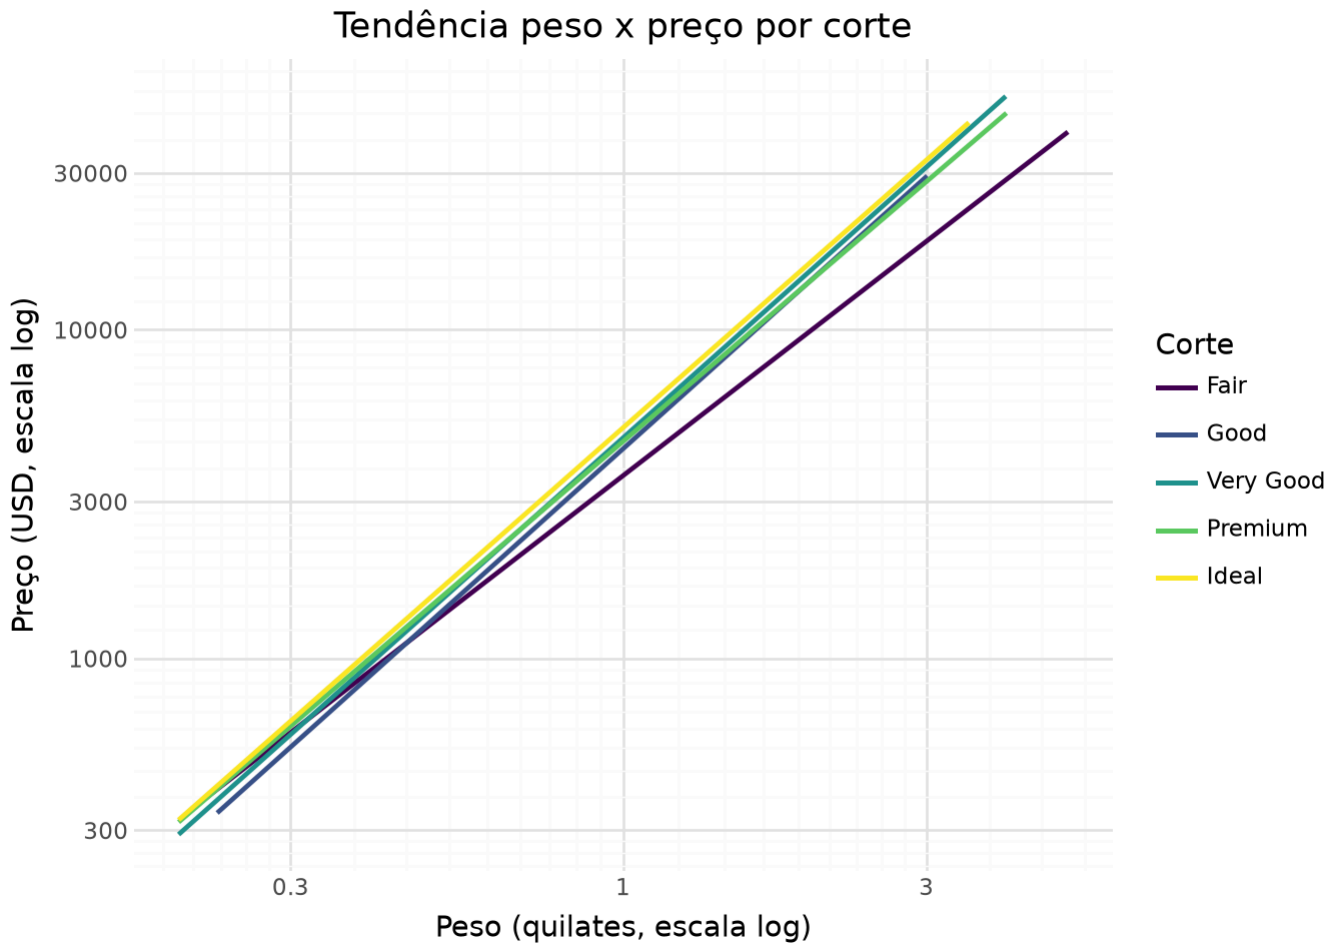
Resposta: Para produzir um gráfico de boa qualidade, tomei as seguintes ações: (i) usei um gráfico de dispersão, adequado para duas variáveis numéricas; (ii) apliquei transparência e reduzi o tamanho dos pontos para mitigar o *overplotting*, já que são mais de 53 mil observações; (iii) usei escala logarítmica nos dois eixos, pois na escala original a relação é curva e a variabilidade do preço cresce com o peso; (iv) adicionei uma reta de tendência; (v) incluí título, rótulos com unidades e tema limpo. O principal achado é uma associação positiva e forte: diamantes mais pesados são mais caros. A relação é não linear na escala original, mas aproximadamente linear em log-log, sugerindo uma relação do tipo potência.

Questão 3

```
p3 = (
    ggplot(diamonds, aes("carat", "price"))
    + geom_point(alpha=0.1, size=0.6)
    + geom_smooth(method="lm", color="red")
    + facet_wrap("~cut", nrow=1)
    + scale_x_log10()
    + scale_y_log10()
    + labs(title="Relação peso x preço por tipo de corte",
           x="Peso (quilates, escala log)", y="Preço (USD, escala log)")
    + theme_minimal()
    + theme(figure_size=(14, 4))
)
p3
```




```
p3b = (
    ggplot(diamonds, aes("carat", "price", color="cut"))
    + geom_smooth(method="lm", se=False)
    + scale_x_log10()
    + scale_y_log10()
    + labs(title="Tendência peso x preço por corte",
           x="Peso (quilates, escala log)", y="Preço (USD, escala log)",
           color="Corte")
    + theme_minimal()
)
p3b
```




```
d = diamonds.assign(lcarat=np.log(diamonds["carat"]),
                    lprice=np.log(diamonds["price"]))
d.groupby("cut", observed=True).apply(
    lambda g: g["lcarat"].corr(g["lprice"]))
```

```
cut
Fair         0.908513
Good         0.968751
Very Good    0.971675
Premium      0.969758
Ideal        0.966188
dtype: float64
```

Resposta: Sim, o padrão geral se repete em todos os cortes: há associação positiva e forte entre peso e preço, com relação aproximadamente linear em log-log. A correlação entre log(peso) e log(preço) é alta em todos os cortes (≥ 0,96), com exceção de *Fair* (0,91), que tem menos observações e maior dispersão. Além disso, o preço médio não segue a ordem de qualidade do corte: *Ideal* tem o menor preço médio (US$ 3.458) e peso médio de 0,70 ct, enquanto *Fair* tem 1,05 ct. Isso mostra que o peso domina o preço e que o corte tem efeito secundário.

Questão 4

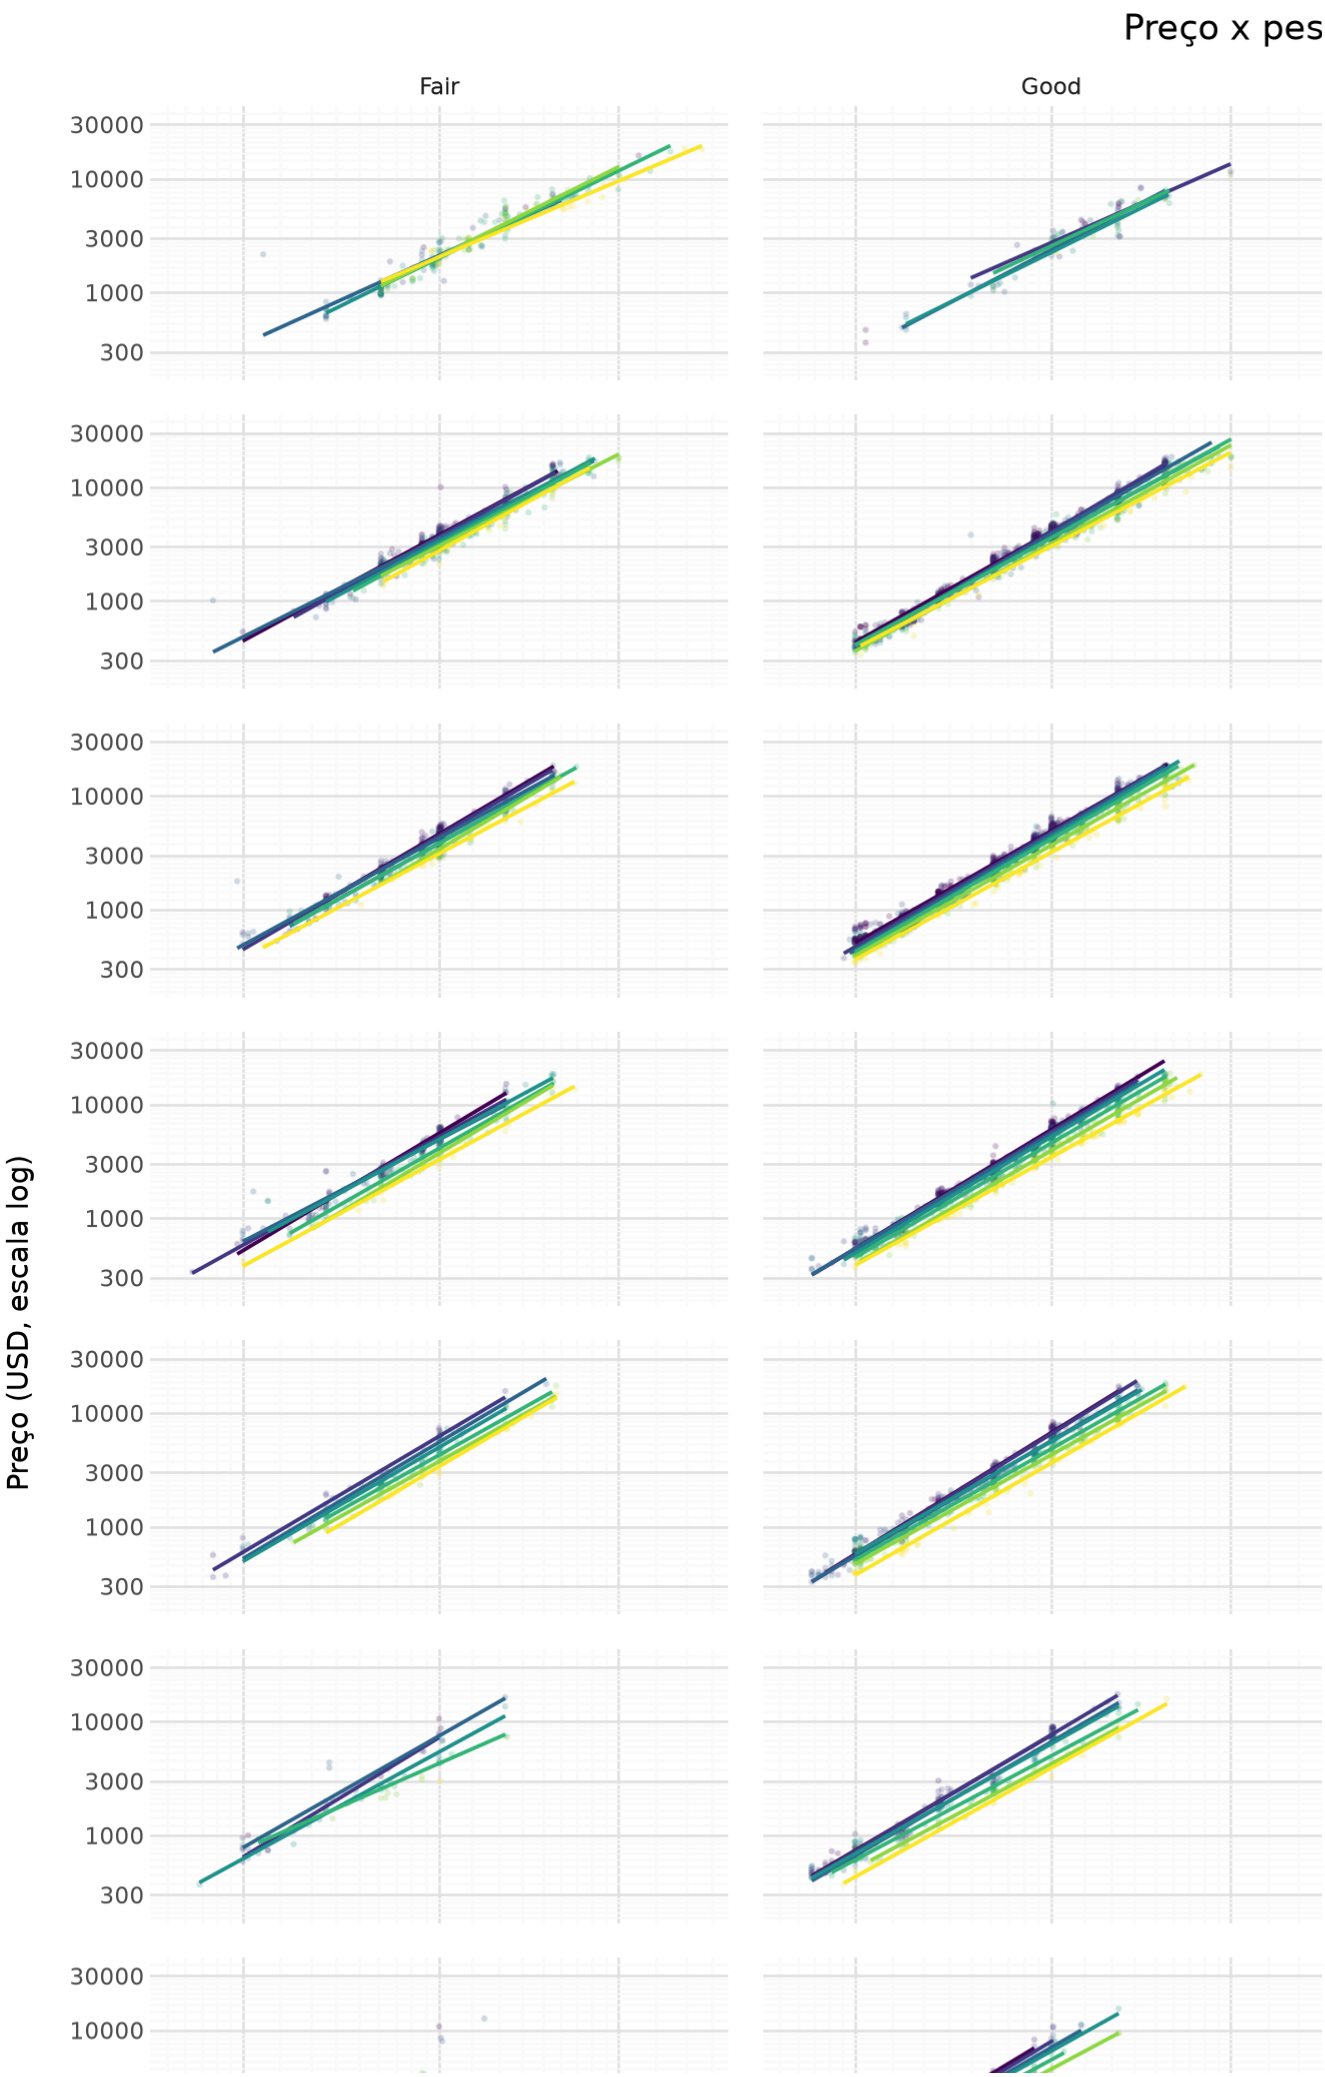
Filtragem: só traço reta de tendência em combinações com pelo menos 10 diamantes.

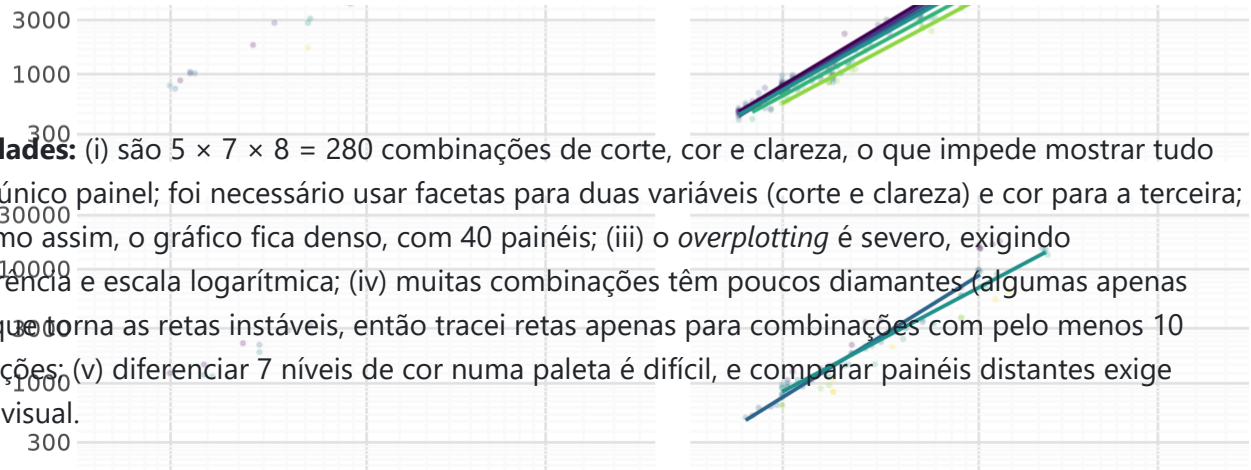
```
d4 = diamonds.copy()
d4["n_grupo"] = d4.groupby(["cut", "color", "clarity"],
                           observed=True)["price"].transform("size")
d4_ok = d4[d4["n_grupo"] >= 10]

print("Combinações possíveis:", 5 * 7 * 8)
print("Combinações com >= 10 diamantes:",
      d4_ok.groupby(["cut", "color", "clarity"], observed=True).ngroups)
```

```
Combinações possíveis: 280
Combinações com >= 10 diamantes: 246
```

```
p4 = (
    ggplot(d4, aes("carat", "price", color="color"))
    + geom_point(alpha=0.15, size=0.4)
    + geom_smooth(data=d4_ok, method="lm", se=False, size=0.8)
    + facet_grid("clarity ~ cut")
    + scale_x_log10()
    + scale_y_log10()
    + labs(title="Preço x peso por corte (colunas), clareza (linhas) e cor (cores)",
           x="Peso (quilates, escala log)", y="Preço (USD, escala log)",
           color="Cor")
    + theme_minimal()
    + theme(figure_size=(18, 14))
)
p4
```


Preço x pes
Fair
Good
Preço (USD, escala log)
30000
10000
3000
1000
300



Dificuldades: (i) são 5 × 7 × 8 = 280 combinações de corte, cor e clareza, o que impede mostrar tudo em um único painel; foi necessário usar facetas para duas variáveis (corte e clareza) e cor para a terceira; (ii) mesmo assim, o gráfico fica denso, com 40 painéis; (iii) o *overplotting* é severo, exigindo transparência e escala logarítmica; (iv) muitas combinações têm poucos diamantes (algumas apenas um), o que torna as retas instáveis, então tracei retas apenas para combinações com pelo menos 10 observações; (v) diferenciar 7 níveis de cor numa paleta é difícil, e comparar painéis distantes exige esforço visual.

Conclusão: A relação entre preço e peso **não é exatamente a mesma** em todas as configurações. A forma geral se mantém (positiva e aproximadamente linear em log-log), mas o nível das retas muda: para o mesmo peso, diamantes com melhor clareza e melhor cor tendem a custar mais. O peso é o fator dominante, e clareza e cor deslocam o nível do preço.